

Instituto Tecnológico de Tijuana

Maestría en Ciencias de la Computación

Clustering No Supervisado del Dataset Palmer Penguins: Comparativa entre K-Means, DBSCAN y Agglomerative Clustering

Materia: Minería de Datos
Profesor: Dr. Mario Garcia
Semestre: Enero – Junio 2026
Alumno: Samuel Hiram Castro Martinez
Matrícula: 25210035
Programa: Maestría en Ciencias de la Computación
Proyecto: Clustering no supervisado sobre Palmer Penguins
Versión: 1.0 (notebook reproducible con figuras y métricas integradas)
Fecha: 26 de Mayo del 2026

Resumen ejecutivo

Este documento reporta una investigación corta de minería de datos sobre el dataset *Palmer Penguins* (Horst et al., 2020; Gorman et al., 2014). Se compara la capacidad de tres algoritmos de clustering no supervisado — K-Means (MacQueen, 1967), DBSCAN (Ester et al., 1996) y Agglomerative Clustering con linkage de Ward (Ward, 1963) — para recuperar automáticamente la estructura de especies a partir únicamente de las cuatro variables morfométricas del dataset, sin utilizar la etiqueta de especie durante el entrenamiento.

Aportes principales

- Flujo de minería de datos completo en un único notebook reproducible: definición del problema, obtención de datos, exploración, preprocesamiento, experimentación, evaluación y conclusiones.
- Comparación cuantitativa de los tres algoritmos con dos métricas complementarias: *Silhouette Score* (interna) y *Adjusted Rand Index* (externa, contra la etiqueta verdadera de especie) (Rand, 1971; Hubert and Arabie, 1985; Rousseeuw, 1987).
- Visualizaciones vectoriales: *pairplot* discriminado por especie, matriz de correlación, método del codo, proyección PCA bidimensional y matriz de confusión.
- Práctica plena de Ciencia 2.0: datos con licencia CC-0, código bajo control de versiones, semillas fijadas (`RANDOM_STATE=42`), `requirements.txt` y notebook ejecutable de principio a fin sin intervención manual.

Resultado del experimento Sobre 333 observaciones limpias del dataset (tras eliminar valores faltantes), **Agglomerative Clustering con linkage de Ward** obtiene el mejor ajuste a la estructura biológica conocida, con un *Adjusted Rand Index* de **0.916** y un *Silhouette Score* de 0.454. K-Means queda muy próximo ($ARI=0.793$) y DBSCAN, pese a maximizar la métrica interna (*Silhouette*=0.557), fusiona las especies *Adelie* y *Chinstrap* en un único cluster denso y produce 33 puntos catalogados como ruido, lo que penaliza su ARI a 0.584.

Defensibilidad académica El experimento es totalmente reproducible: tanto el notebook como las semillas, los hiperparámetros y los hashes del dataset están versionados en el repositorio del proyecto. La sección 6 incluye la tabla comparativa de métricas y la sección 7 las conclusiones con limitaciones y trabajo futuro. Los apéndices recogen el código fuente esencial y la checklist de reproducibilidad.

Índice

Resumen ejecutivo	1
1. Introducción	5
2. Planteamiento del problema	5
3. Objetivo general	5
4. Objetivos específicos	6
5. Estructura del documento	6
6. Marco teórico	6
6.1. Minería de datos y aprendizaje no supervisado	6
6.2. K-Means	6
6.3. DBSCAN	7
6.4. Agglomerative Clustering	7
6.5. Métricas de evaluación	7
6.6. Reducción de dimensionalidad por PCA	8
6.7. Ciencia 2.0 y reproducibilidad	8
7. Metodología	8
7.1. Pipeline general	8
7.2. Pseudocódigo del experimento	9
7.3. Variables del dataset	9
8. Diseño y ejecución de los experimentos	9
8.1. Exploración de datos	10
8.2. Determinación del número de clusters	11
8.3. Configuración de los algoritmos	12
9. Resultados	12

9.1. Métricas comparativas	12
9.2. Visualización de los clusters	12
9.3. Matriz de confusión del mejor modelo	13
9.4. Discusión	13
10. Conclusiones	14
10.1. Aportes del proyecto	14
10.2. Limitaciones	14
10.3. Trabajo futuro	15
Checklist de Ciencia 2.0	15
A. Apéndice: código fuente esencial	15
A.1. Carga y preprocesamiento	15
A.2. Comparación de algoritmos	16
B. Apéndice: instrucciones de reproducibilidad	16
B.1. Estructura del repositorio	16
B.2. Ejecución local	17
B.3. Ejecución en Google Colab	17
B.4. Compilación del reporte LaTeX	17
B.5. Checklist de Ciencia 2.0	18

Índice de figuras

1. <i>Pairplot</i> de las cuatro variables morfológicas discriminado por especie. <i>Gentoo</i> se separa claramente del par <i>Adelie/Chinstrap</i> , especialmente en <code>flipper_length_mm</code> y <code>body_mass_g</code> . <i>Adelie</i> y <i>Chinstrap</i> comparten masa corporal y longitud de aleta similares, pero se distinguen por la longitud del pico.	10
2. Matriz de correlación de Pearson entre las variables numéricas. La correlación más fuerte se da entre <code>flipper_length_mm</code> y <code>body_mass_g</code> ($\rho \approx 0,87$). La correlación negativa de $-0,58$ entre <code>bill_depth_mm</code> y <code>flipper_length_mm</code> es una manifestación de la paradoja de Simpson causada por la mezcla de especies. . .	11
3. Método del codo para K-Means sobre las variables estandarizadas. El descenso de la inercia presenta un quiebre en $k = 3$	11

4. Proyección PCA 2D de las 333 observaciones. De izquierda a derecha: etiqueta verdadera de especie, K-Means, DBSCAN y Agglomerative. El ARI consignado en el título de cada panel corresponde al modelo correspondiente. 13
5. Matriz de confusión de Agglomerative Clustering (linkage=Ward) contra la etiqueta verdadera de especie. El emparejamiento cluster–especie es directo y reproduce la estructura biológica. 13

Índice de tablas

1. Variables del dataset Palmer Penguins consideradas en el experimento. 9
2. Hiperparámetros de los algoritmos comparados. 12
3. Métricas de clustering — mayor es mejor en ambas columnas. 12

1. Introducción

La minería de datos articula un conjunto de técnicas computacionales orientadas a descubrir patrones útiles en grandes volúmenes de información, conjugando estadística, aprendizaje automático y visualización (Han et al., 2011; Witten et al., 2016). En su modalidad no supervisada, la disciplina busca estructura latente sin disponer de etiquetas: el clustering es su instancia canónica.

El dataset *Palmer Penguins* (Horst et al., 2020; Gorman et al., 2014) se ha consolidado como una alternativa moderna al clásico *Iris*, debido a que ofrece características físicas de tres especies de pingüinos (*Adelie*, *Chinstrap* y *Gentoo*) en tres islas del archipiélago Palmer (Antártida). Su tamaño compacto, su licencia abierta y la presencia controlada de valores faltantes y solapamiento entre especies lo convierten en un banco de pruebas ideal para enseñar y comparar algoritmos de clustering en un contexto reproducible.

2. Planteamiento del problema

Los enfoques supervisados de clasificación requieren etiquetas, las cuales no siempre están disponibles — por ejemplo, en biología de campo o en estudios exploratorios. La pregunta de investigación de este proyecto es:

¿Es posible recuperar la estructura natural de las tres especies de pingüinos del archipiélago Palmer a partir únicamente de variables morfológicas (longitud y profundidad del pico, longitud de la aleta y masa corporal) mediante algoritmos de clustering no supervisado, y qué algoritmo lo hace mejor?

La hipótesis es que algoritmos sensibles a la geometría global del espacio de características (K-Means y Agglomerative con linkage de Ward) recuperarán mejor la partición real que algoritmos basados puramente en densidad local (DBSCAN), debido a que las especies presentan tamaños de grupo similares y no exhiben densidades drásticamente distintas.

3. Objetivo general

Diseñar, ejecutar y reportar un experimento de minería de datos — siguiendo prácticas de Ciencia 2.0 — que compare K-Means, DBSCAN y Agglomerative Clustering sobre el dataset Palmer Penguins, evaluando con métricas interna (Silhouette) y externa (Adjusted Rand Index) la calidad de la agrupación obtenida.

4. Objetivos específicos

- Realizar el análisis exploratorio de datos (EDA) con estadísticas descriptivas, distribución por clase, valores faltantes y correlaciones.
- Diseñar un pipeline de preprocesamiento que elimine NaN y estandarice las variables numéricas mediante `StandardScaler`.
- Ajustar y comparar K-Means, DBSCAN y Agglomerative Clustering con hiperparámetros explícitamente documentados.
- Calcular y reportar Silhouette Score y Adjusted Rand Index para los tres modelos.
- Visualizar los clusters obtenidos sobre la proyección PCA bidimensional y construir la matriz de confusión del mejor algoritmo.
- Publicar todos los artefactos (notebook, dataset, requirements, README, presentación, figuras) en un repositorio reproducible.

5. Estructura del documento

El reporte se organiza en seis secciones principales y dos apéndices. La sección 2 establece el marco teórico de los algoritmos y las métricas. La sección 3 describe la metodología y el pipeline de minería de datos. La sección 4 detalla los experimentos. La sección 5 presenta los resultados con tablas y figuras. La sección 6 concluye con limitaciones y trabajo futuro. El apéndice A contiene los fragmentos esenciales de código y el apéndice B la checklist de reproducibilidad de Ciencia 2.0.

6. Marco teórico

6.1. Minería de datos y aprendizaje no supervisado

La minería de datos se define como el proceso no trivial de extracción de patrones válidos, novedosos, potencialmente útiles y comprensibles a partir de los datos (Fayyad et al., 1996). Dentro del aprendizaje automático, se distinguen tres familias: supervisado (con etiquetas), no supervisado (sin etiquetas) y semi-supervisado. El *clustering* pertenece a la segunda y busca particionar el conjunto $X = \{x_1, \dots, x_n\}$, $x_i \in \mathbb{R}^d$, en k subconjuntos $C_1, \dots, C_k$ que maximicen la similitud intra-cluster y minimicen la similitud inter-cluster (Jain et al., 1999; Jain, 2010).

6.2. K-Means

K-Means (MacQueen, 1967; Lloyd, 1982) minimiza la suma de cuadrados intra-cluster (SSE o inercia):

$$\mathcal{J}(C_1, \dots, C_k) = \sum_{j=1}^k \sum_{x_i \in C_j} \|x_i - \mu_j\|_2^2, \quad (1)$$

donde μ_j es el centroide del cluster j . El algoritmo de Lloyd alterna dos pasos: asignación de cada x_i al centroide más cercano y recálculo de los centroides como medias de sus miembros,

hasta convergencia. Es eficiente ($O(nkt)$ para t iteraciones) pero presenta tres limitaciones bien conocidas: requiere fijar k a priori, es sensible a la inicialización (mitigado con *k-means++* (Arthur and Vassilvitskii, 2007)) y asume clusters convexos de tamaño similar.

6.3. DBSCAN

DBSCAN (*Density-Based Spatial Clustering of Applications with Noise*) (Ester et al., 1996) construye clusters como regiones de alta densidad separadas por regiones de baja densidad. Define un punto como *núcleo* si tiene al menos `min_samples` vecinos dentro de un radio `eps`; los clusters son componentes conexas de núcleos densamente conectados, y los puntos no alcanzables se etiquetan como ruido (-1). Sus ventajas son la detección automática del número de clusters y la robustez al ruido; sus desventajas son la sensibilidad al par $(\epsilon, \text{minPts})$ y la dificultad de manejar densidades heterogéneas.

6.4. Agglomerative Clustering

El clustering jerárquico aglomerativo (Ward, 1963; Murtagh, 1983) parte con cada observación como su propio cluster y fusiona iterativamente el par más cercano, según un criterio de *linkage*. Con linkage de Ward, en cada paso se fusiona la pareja (A, B) que minimiza el incremento de la suma de cuadrados:

$$\Delta(A, B) = \frac{|A| |B|}{|A| + |B|} \|\mu_A - \mu_B\|_2^2. \quad (2)$$

Este criterio favorece clusters compactos y de varianza homogénea, característica que se ajusta bien al dataset Palmer Penguins una vez estandarizado.

6.5. Métricas de evaluación

Silhouette Score (Rousseeuw, 1987). Para cada observación x_i asignada al cluster C_j se define

$$s(x_i) = \frac{b(x_i) - a(x_i)}{\max\{a(x_i), b(x_i)\}}, \quad s(x_i) \in [-1, 1], \quad (3)$$

donde $a(x_i)$ es la distancia promedio de x_i a los demás puntos de su cluster y $b(x_i)$ es la mínima distancia promedio de x_i a otro cluster. Valores cercanos a 1 indican una asignación coherente; cercanos a 0 indican frontera; negativos sugieren mal asignación.

Adjusted Rand Index (Rand, 1971; Hubert and Arabie, 1985). Compara una partición candidata U con una partición de referencia V contando los pares de observaciones que coinciden o difieren en ambas particiones, y ajusta el índice de Rand para que tome el valor esperado 0 bajo asignación aleatoria. Rango $[-1, 1]$: 1 indica coincidencia perfecta. En este proyecto el ARI se calcula contra la etiqueta verdadera de especie (no usada en el entrenamiento).

6.6. Reducción de dimensionalidad por PCA

El *Análisis de Componentes Principales* (Pearson, 1901; Jolliffe, 2002) proyecta los datos en las direcciones de máxima varianza. En este trabajo se utiliza únicamente con fines visuales: la geometría de los clusters en $\mathbb{R}^4$ se proyecta a $\mathbb{R}^2$ para inspección.

6.7. Ciencia 2.0 y reproducibilidad

La práctica de Ciencia 2.0 (Shneiderman, 2008; Wilkinson et al., 2016) establece que los productos de investigación deben ser *abiertos, citables, ejecutables y verificables* por terceros. En este proyecto se materializa fijando `RANDOM_STATE = 42`, declarando versiones exactas en `requirements.txt`, alojando el dataset bajo licencia CC-0 y entregando un notebook reproducible (Kluyver et al., 2016).

7. Metodología

El experimento sigue el flujo canónico de minería de datos KDD (Fayyad et al., 1996), instanciado como una sucesión de siete etapas explícitas que coinciden con las fases solicitadas en el enunciado del proyecto.

7.1. Pipeline general

1. **Definición del problema.** Recuperar la estructura de las tres especies de pingüinos a partir de variables morfométricas, sin supervisión.
2. **Adquisición de los datos.** Descarga del archivo `penguins.csv` del repositorio oficial `allisonhorst/palmerpenguins` (CC-0). En el notebook, si el archivo local no existe se obtiene automáticamente vía `urllib.request`, garantizando ejecución en Google Colab sin pasos manuales.
3. **Análisis exploratorio.** Conteo por especie, `describe()`, recuento de NaN, matriz de correlación y `pairplot` discriminado por clase.
4. **Preprocesamiento.** Eliminación de filas con NaN en variables numéricas y en `species`; estandarización de las cuatro variables numéricas con `StandardScaler`.
5. **Diseño de experimentos.** Aplicación de K-Means ($k = 3$, $n_{init} = 10$), DBSCAN ($\epsilon = 0,6$, $\text{minPts} = 5$) y Agglomerative ($k = 3$, `linkage=Ward`); semilla `RANDOM_STATE = 42` en todos los pasos estocásticos.
6. **Evaluación.** Cálculo de Silhouette Score (excluyendo los puntos de ruido de DBSCAN), Adjusted Rand Index contra la etiqueta verdadera, matriz de confusión del mejor modelo y visualización en el plano PCA.
7. **Conclusiones.** Discusión de los resultados, limitaciones y trabajo futuro.

7.2. Pseudocódigo del experimento

Listing 1: Pipeline esencial de minería de datos.

```

RANDOM_STATE = 42
df = read_csv("data/penguins.csv")
df_clean = df.dropna(subset=NUM_COLS + ["species"]).reset_index(drop=True)
X = StandardScaler().fit_transform(df_clean[NUM_COLS])
y_true = LabelEncoder().fit_transform(df_clean["species"])

models = {
    "K-Means": KMeans(n_clusters=3, n_init=10, random_state=RANDOM_STATE),
    "DBSCAN": DBSCAN(eps=0.6, min_samples=5),
    "Agglomerative": AgglomerativeClustering(n_clusters=3, linkage="ward"),
}

for name, m in models.items():
    labels = m.fit_predict(X)
    sil = silhouette_score(X[labels != -1], labels[labels != -1])
    ari = adjusted_rand_score(y_true, labels)
    log(name, sil, ari)

```

7.3. Variables del dataset

La tabla 1 resume las variables empleadas en el modelado. Únicamente las cuatro numéricas alimentan los algoritmos; *species* se reserva como verdad de campo para la métrica externa.

Tabla 1: Variables del dataset Palmer Penguins consideradas en el experimento.

Variable	Descripción	Tipo
bill_length_mm	Longitud del pico (culmen) en milímetros	Númérica continua
bill_depth_mm	Profundidad del pico en milímetros	Númérica continua
flipper_length_mm	Longitud de la aleta en milímetros	Númérica continua
body_mass_g	Masa corporal en gramos	Númérica continua
species	<i>Adelie</i> , <i>Chinstrap</i> o <i>Gentoo</i>	Catagórica (verdad)

8. Diseño y ejecución de los experimentos

8.1. Exploración de datos

El dataset cargado contiene 344 observaciones y 8 columnas (4 numéricas, 4 categóricas). La distribución por especie es desbalanceada: *Adelie* con 152 ejemplares, *Gentoo* con 124 y *Chinstrap* con 68. Tras eliminar las filas con valores faltantes en cualquiera de las cuatro variables numéricas o en especie, el dataset definitivo queda en 333 filas.




Figura 1: Pairplot de las cuatro variables morfométricas discriminado por especie. *Gentoo* se separa claramente del par *Adelie*/*Chinstrap*, especialmente en `flipper_length_mm` y `body_mass_g`. *Adelie* y *Chinstrap* comparten masa corporal y longitud de aleta similares, pero se distinguen por la longitud del pico.




Figura 2: Matriz de correlación de Pearson entre las variables numéricas. La correlación más fuerte se da entre `flipper_length_mm` y `body_mass_g` ($\rho \approx 0,87$). La correlación negativa de $-0,58$ entre `bill_depth_mm` y `flipper_length_mm` es una manifestación de la paradoja de Simpson causada por la mezcla de especies.

8.2. Determinación del número de clusters

Antes de fijar $k = 3$ se aplicó el *método del codo* para K-Means barriendo $k \in \{1, \dots, 8\}$. La figura 3 muestra la inercia decreciente con un quiebre visible en $k = 3$, congruente con la presencia de tres especies en el dataset.




Figura 3: Método del codo para K-Means sobre las variables estandarizadas. El descenso de la inercia presenta un quiebre en $k = 3$.

8.3. Configuración de los algoritmos

La tabla 2 consigna los hiperparámetros utilizados; todos los demás se dejan en los valores por omisión de `scikit-learn`. La semilla `RANDOM_STATE = 42` aplica a K-Means; DBSCAN y Agglomerative son deterministas.

Tabla 2: Hiperparámetros de los algoritmos comparados.

Algoritmo	Hiperparámetro	Justificación
K-Means	<code>n_clusters=3</code> <code>n_init=10</code>	<code>k = 3</code> por método del codo y por la verdad biológica.
DBSCAN	<code>eps=0.6</code> , <code>min_samples=5</code>	Valor por defecto típico tras estandarización; sin búsqueda fina.
Agglomerative	<code>n_clusters=3</code> <code>linkage="ward"</code>	Ward favorece clusters compactos y de varianza homogénea.

9. Resultados

9.1. Métricas comparativas

La tabla 3 reporta el Silhouette Score y el Adjusted Rand Index obtenidos por cada algoritmo sobre las 333 observaciones limpias. Los valores son reproducibles a partir del notebook con `RANDOM_STATE = 42`.

Tabla 3: Métricas de clustering — mayor es mejor en ambas columnas.

Algoritmo	Silhouette	ARI	Ruido
K-Means	0.447	0.793	0
DBSCAN	0.557	0.584	33
Agglomerative (<i>Ward</i>)	0.454	0.916	0

9.2. Visualización de los clusters

La figura 4 muestra la proyección PCA bidimensional. La primera componente captura el grueso de la varianza ($\approx 88\%$ entre PC1 y PC2). El panel *Etiqueta verdadera* se incluye como referencia visual: nótese cómo *Gentoo* se separa nítidamente y cómo *Adelie* y *Chinstrap* comparten frontera.




Figura 4: Proyección PCA 2D de las 333 observaciones. De izquierda a derecha: etiqueta verdadera de especie, K-Means, DBSCAN y Agglomerative. El ARI consignado en el título de cada panel corresponde al modelo correspondiente.

9.3. Matriz de confusión del mejor modelo

Dado que Agglomerative obtiene el mayor ARI, se reporta su matriz de confusión contra la verdad de campo. La figura 5 muestra que los clusters numéricos asignados por el algoritmo se corresponden con las tres especies con un error de asignación pequeño concentrado en la frontera *Adelie/Chinstrap*.




Figura 5: Matriz de confusión de Agglomerative Clustering (linkage=Ward) contra la etiqueta verdadera de especie. El emparejamiento cluster–especie es directo y reproduce la estructura biológica.

9.4. Discusión

Los resultados confirman parcialmente la hipótesis. **Agglomerative** con linkage de Ward es el algoritmo más preciso en términos de ARI (0.916), seguido por **K-Means** (0.793). Ambos métodos asumen clusters convexos de varianza similar — supuesto que se cumple razonablemente en este dataset tras estandarización.

DBSCAN obtiene la mejor compacidad interna (Silhouette = 0,557) porque ignora los 33 puntos marcados como ruido, lo que infla artificialmente la métrica. En la práctica, fusiona *Adelie* y *Chinstrap* en un único cluster denso, hecho que penaliza su ARI. Una búsqueda fina del par $(\epsilon, \text{minPts})$ mediante la curva k -distance (Ester et al., 1996; Schubert et al., 2017) podría mejorar su desempeño, pero está fuera del alcance de este trabajo corto.

El comportamiento es congruente con la literatura: para datasets pequeños, de baja dimensionalidad y con clusters geoméricamente bien separados, los algoritmos centroide-céntricos y jerárquicos suelen superar a los basados en densidad (Xu and Wunsch, 2005; Saxena et al., 2017).

10. Conclusiones

Se aplicó un flujo completo de minería de datos sobre el dataset Palmer Penguins comparando tres algoritmos de clustering no supervisado. La hipótesis inicial — que algoritmos sensibles a la geometría global recuperarían mejor la estructura biológica que algoritmos basados en densidad — queda confirmada por las métricas: Agglomerative Clustering con linkage de Ward obtiene un ARI de 0.916, K-Means un ARI de 0.793 y DBSCAN un ARI de 0.584.

El dataset resultó ideal para el ejercicio docente: tamaño manejable, tres especies bien definidas, presencia controlada de valores faltantes y suficiente solapamiento entre *Adelie* y *Chinstrap* como para que los algoritmos tengan que esforzarse. La estandarización previa de las cuatro variables fue clave; sin ella, `body_mass_g` (en gramos) dominaría las distancias frente a `bill_depth_mm` (en milímetros).

10.1. Aportes del proyecto

- Notebook reproducible `notebook.ipynb` ejecutable en Jupyter local y en Google Colab sin pasos manuales.
- Comparativa cuantitativa de tres algoritmos con dos métricas complementarias — interna y externa — sobre el mismo pipeline.
- Cinco figuras vectoriales generadas por el propio notebook: pairplot, matriz de correlación, método del codo, proyección PCA y matriz de confusión.
- Presentación PowerPoint (5 diapositivas según rúbrica) generada programáticamente y sincronizada con las métricas del notebook.
- Repositorio organizado siguiendo Ciencia 2.0 (README, requirements, datos versionados, semillas fijadas).

10.2. Limitaciones

- Sólo se usaron las cuatro variables numéricas. Las variables categóricas `sex` e `island` contienen información discriminante (por ejemplo, las islas de *Gentoo* y *Chinstrap* son disjuntas) y podrían mejorar la separación tras encoding.
- Los hiperparámetros de DBSCAN se fijaron a un valor estándar; una búsqueda fina con la curva k -distance probablemente lo equipararía a K-Means en este dataset.

- No se midió la estabilidad de los clusters frente a remuestreo. Un análisis con *bootstrap* reforzaría la validez de los resultados (Hennig, 2007).

10.3. Trabajo futuro

Como continuación natural se contemplan: integración de las variables categóricas mediante *one-hot encoding* o *Gower distance*; comparación con Gaussian Mixture Models (McLachlan and Peel, 2000) para clusters elípticos con asignación probabilística; visualización no lineal con UMAP o t-SNE; y validación de estabilidad con *bootstrap* y el índice de Jaccard (Hennig, 2007). En un horizonte más amplio, sería interesante replicar la metodología sobre el dataset *Iris* y sobre *Pima Indians Diabetes* para contrastar dominios.

Checklist de Ciencia 2.0

- Dataset con licencia abierta (CC-0) y enlace al repositorio oficial.
- Código fuente íntegro en el notebook, sin dependencias propietarias.
- Semillas aleatorias fijadas (RANDOM_STATE=42).
- `requirements.txt` con las librerías necesarias y sus versiones mínimas.
- Notebook ejecutable de principio a fin sin intervención manual.
- Reporte en L^AT_EX con figuras vectoriales y citas verificables.
- Presentación de cinco diapositivas alineada con la rúbrica.

A. Apéndice: código fuente esencial

Este apéndice contiene los fragmentos esenciales de Python que reproducen el experimento de principio a fin. El notebook completo se encuentra en `notebook.ipynb` dentro del repositorio del proyecto.

A.1. Carga y preprocesamiento

Listing 2: Carga, limpieza y estandarización del dataset.

```
import os, urllib.request
import pandas as pd
from sklearn.preprocessing import StandardScaler, LabelEncoder

RANDOM_STATE = 42
NUM_COLS = ["bill_length_mm", "bill_depth_mm",
            "flipper_length_mm", "body_mass_g"]

DATA_URL = ("https://raw.githubusercontent.com/allisonhorst/"
            "palmerpenguins/main/inst/extdata/penguins.csv")
LOCAL_PATH = "data/penguins.csv"
```



```

if not os.path.exists(LOCAL_PATH):
    os.makedirs("data", exist_ok=True)
    urllib.request.urlretrieve(DATA_URL, LOCAL_PATH)

df = pd.read_csv(LOCAL_PATH)
df_clean = df.dropna(subset=NUM_COLS + ["species"]).reset_index(drop=True)

X = StandardScaler().fit_transform(df_clean[NUM_COLS])
y_true = LabelEncoder().fit_transform(df_clean["species"])

```

A.2. Comparación de algoritmos

Listing 3: Ajuste y evaluación de los tres modelos.

```

import numpy as np
from sklearn.cluster import KMeans, DBSCAN, AgglomerativeClustering
from sklearn.metrics import silhouette_score, adjusted_rand_score

models = {
    "K-Means": KMeans(n_clusters=3, n_init=10,
                      random_state=RANDOM_STATE),
    "DBSCAN": DBSCAN(eps=0.6, min_samples=5),
    "Agglomerative": AgglomerativeClustering(n_clusters=3,
                                              linkage="ward"),
}

for name, m in models.items():
    labels = m.fit_predict(X)
    mask = labels != -1
    sil = (silhouette_score(X[mask], labels[mask]))
    if len(set(labels[mask])) > 1 else np.nan)
    ari = adjusted_rand_score(y_true, labels)
    n_noise = int((labels == -1).sum())
    print(f"{name:15s} sil={sil:.3f} ari={ari:.3f} ruido={n_noise}")

```

B. Apéndice: instrucciones de reproducibilidad

B.1. Estructura del repositorio

Listing 4: Disposición de archivos del proyecto.

```

mineria/
+- notebook.ipynb Notebook principal (Jupyter / Google Colab)
+- README.md Resumen del proyecto y guía de ejecución

```

```
+ requirements.txt Dependencias minimas con version
+ data/
| +- penguins.csv Dataset Palmer Penguins (CC-0)
+ images/ Figuras vectoriales generadas por el notebook
+ presentacion.pptx Presentacion de 5 diapositivas
+ report/
  +- main.tex Reporte LaTeX (este documento)
  +- sections/ Secciones modulares
  +- images/ Copia de figuras para el reporte
  +- references.bib Bibliografia
```

B.2. Ejecución local

Listing 5: Reproducción del experimento en local.

```
git clone <repo-url> mineria
cd mineria
python -m venv venv
venv\Scripts\activate # Windows (en Linux/Mac: source venv/bin/activate)
pip install -r requirements.txt
jupyter notebook notebook.ipynb
```

B.3. Ejecución en Google Colab

1. Subir notebook.ipynb a Google Drive.
2. Abrirlo con Google Colab.
3. Ejecutar Entorno de ejecución → Ejecutar todo.
4. El dataset se descarga automáticamente desde el repositorio oficial si no está disponible localmente.

B.4. Compilación del reporte LaTeX

Listing 6: Compilación del PDF en el directorio report/.

```
cd report
pdflatex main.tex
bibtex main
pdflatex main.tex
pdflatex main.tex
```

B.5. Checklist de Ciencia 2.0

- ✓ Datos abiertos con licencia CC-0 y enlace al repositorio fuente.
- ✓ Código abierto en notebook y scripts auxiliares.
- ✓ Semillas aleatorias fijadas (`RANDOM_STATE = 42`).
- ✓ Dependencias declaradas con versiones mínimas (`requirements.txt`).
- ✓ Notebook ejecutable de principio a fin sin pasos manuales.
- ✓ Reporte LaTeX y presentación generados a partir de los mismos resultados.

Referencias

- Arthur, D. and Vassilvitskii, S. (2007). k-means++: The advantages of careful seeding. In *Proceedings of the Eighteenth Annual ACM-SIAM Symposium on Discrete Algorithms*, pages 1027–1035.
- Ester, M., Kriegel, H.-P., Sander, J., and Xu, X. (1996). A density-based algorithm for discovering clusters in large spatial databases with noise. In *Proceedings of the Second International Conference on Knowledge Discovery and Data Mining (KDD-96)*, pages 226–231.
- Fayyad, U., Piatetsky-Shapiro, G., and Smyth, P. (1996). From data mining to knowledge discovery in databases. *AI Magazine*, 17(3):37–54.
- Gorman, K. B., Williams, T. D., and Fraser, W. R. (2014). Ecological sexual dimorphism and environmental variability within a community of Antarctic penguins (genus *Pygoscelis*). *PLoS ONE*, 9(3):e90081.
- Han, J., Kamber, M., and Pei, J. (2011). *Data Mining: Concepts and Techniques*. Morgan Kaufmann, 3 edition.
- Hennig, C. (2007). Cluster-wise assessment of cluster stability. *Computational Statistics & Data Analysis*, 52(1):258–271.
- Horst, A. M., Hill, A. P., and Gorman, K. B. (2020). palmerpenguins: Palmer archipelago (antarctica) penguin data. *R package version 0.1.0*.
- Hubert, L. and Arabie, P. (1985). Comparing partitions. *Journal of Classification*, 2(1):193–218.
- Jain, A. K. (2010). Data clustering: 50 years beyond K-means. *Pattern Recognition Letters*, 31(8):651–666.
- Jain, A. K., Murty, M. N., and Flynn, P. J. (1999). Data clustering: A review. *ACM Computing Surveys*, 31(3):264–323.
- Jolliffe, I. T. (2002). *Principal Component Analysis*. Springer, New York, 2 edition.
- Kluyver, T., Ragan-Kelley, B., Pérez, F., et al. (2016). Jupyter notebooks — a publishing format for reproducible computational workflows. In *Positioning and Power in Academic Publishing: Players, Agents and Agendas*, pages 87–90.

- Lloyd, S. P. (1982). Least squares quantization in PCM. *IEEE Transactions on Information Theory*, 28(2):129–137.
- MacQueen, J. (1967). Some methods for classification and analysis of multivariate observations. In *Proceedings of the Fifth Berkeley Symposium on Mathematical Statistics and Probability*, volume 1, pages 281–297. University of California Press.
- McLachlan, G. J. and Peel, D. (2000). *Finite Mixture Models*. Wiley, New York.
- Murtagh, F. (1983). A survey of recent advances in hierarchical clustering algorithms. *The Computer Journal*, 26(4):354–359.
- Pearson, K. (1901). On lines and planes of closest fit to systems of points in space. *Philosophical Magazine*, 2(11):559–572.
- Rand, W. M. (1971). Objective criteria for the evaluation of clustering methods. *Journal of the American Statistical Association*, 66(336):846–850.
- Rousseeuw, P. J. (1987). Silhouettes: A graphical aid to the interpretation and validation of cluster analysis. *Journal of Computational and Applied Mathematics*, 20:53–65.
- Saxena, A., Prasad, M., Gupta, A., Bharill, N., Patel, O. P., Tiwari, A., Er, M. J., Ding, W., and Lin, C.-T. (2017). A review of clustering techniques and developments. *Neurocomputing*, 267:664–681.
- Schubert, E., Sander, J., Ester, M., Kriegel, H.-P., and Xu, X. (2017). DBSCAN revisited, revisited: Why and how you should (still) use DBSCAN. *ACM Transactions on Database Systems*, 42(3):1–21.
- Shneiderman, B. (2008). Science 2.0. *Science*, 319(5868):1349–1350.
- Ward, J. H. (1963). Hierarchical grouping to optimize an objective function. *Journal of the American Statistical Association*, 58(301):236–244.
- Wilkinson, M. D., Dumontier, M., Aalbersberg, I. J., et al. (2016). The FAIR guiding principles for scientific data management and stewardship. *Scientific Data*, 3:160018.
- Witten, I. H., Frank, E., Hall, M. A., and Pal, C. J. (2016). *Data Mining: Practical Machine Learning Tools and Techniques*. Morgan Kaufmann, 4 edition.
- Xu, R. and Wunsch, D. (2005). Survey of clustering algorithms. *IEEE Transactions on Neural Networks*, 16(3):645–678.